

# Analisis de tasa de Mortalidad en argentina(1990-2021)

Autor: Pedro Burgos

Datos: <https://datos.gob.ar/dataset/salud-tasa-mortalidad-infantil>

Herramientas:

```
In [1]: import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
```

```
In [2]: ds = pd.read_csv("tasa-mortalidad-infantil-deis-1990-2021.csv")
```

```
In [3]: ds.head(5)
#Veamos que contiene el dataset.
```

```
Out[3]:
```

	indice_tiempo	mortalidad_infantil_argentina	mortalidad_infantil_caba	mortalidad_in
0	1990-01-01	25.6	16.8	
1	1991-01-01	24.7	15.2	
2	1992-01-01	23.9	14.9	
3	1993-01-01	22.9	14.6	
4	1994-01-01	22.0	14.3	

5 rows × 26 columns

```
In [4]: ds.tail(5)
```

```
Out[4]:
```

	indice_tiempo	mortalidad_infantil_argentina	mortalidad_infantil_caba	mortalidad_i
27	2017-01-01	9.3	6.9	
28	2018-01-01	8.8	6.0	
29	2019-01-01	9.2	7.3	
30	2020-01-01	8.4	4.9	
31	2021-01-01	8.0	4.6	

5 rows × 26 columns

```
In [5]: #El dataset solo al parecer contiene un tipo de indice de tiempo y la can
#De cada provincia + caba entre los años 1990-2021 siempre evaluando deso
#para poder usar la columna de tiempo cambie el nombre por comodidad.
```

```
ds=ds.rename(columns={"indice_tiempo": "year"})
```


```
In [6]: ds.info()  
#reviso si hay nulos en la columnas y no hay segun non-null ,con esta inf  
#puedo dar por sentado el filtrado o limpieza , ademas que con la natural  
#de lo mismo datos no puedo realizar tantas operaciones sino de comparaci
```

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 32 entries, 0 to 31  
Data columns (total 26 columns):  
#   Column                                     Non-Null Count  Dtype  
---  -  
0   year                                     32 non-null     object  
1   mortalidad_infantil_argentina           32 non-null     float64  
2   mortalidad_infantil_caba                 32 non-null     float64  
3   mortalidad_infantil_buenosaires          32 non-null     float64  
4   mortalidad_infantil_catamarca            32 non-null     float64  
5   mortalidad_infantil_cordoba              32 non-null     float64  
6   mortalidad_infantil_corrientes           32 non-null     float64  
7   mortalidad_infantil_chaco                32 non-null     float64  
8   mortalidad_infantil_chubut               32 non-null     float64  
9   mortalidad_infantil_entrerios            32 non-null     float64  
10  mortalidad_infantil_formosa              32 non-null     float64  
11  mortalidad_infantil_jujuy                32 non-null     float64  
12  mortalidad_infantil_lapampa              32 non-null     float64  
13  mortalidad_infantil_larioja              32 non-null     float64  
14  mortalidad_infantil_mendoza              32 non-null     float64  
15  mortalidad_infantil_misiones             32 non-null     float64  
16  mortalidad_infantil_neuquen              32 non-null     float64  
17  mortalidad_infantil_rionegro             32 non-null     float64  
18  mortalidad_infantil_salta                32 non-null     float64  
19  mortalidad_infantil_sanjuan              32 non-null     float64  
20  mortalidad_infantil_sanluis              32 non-null     float64  
21  mortalidad_infantil_santacruz            32 non-null     float64  
22  mortalidad_infantil_santafe              32 non-null     float64  
23  mortalidad_infantil_santiagodelesterro   32 non-null     float64  
24  mortalidad_infantil_tucuman              32 non-null     float64  
25  mortalidad_infantil_tierradelfuego       32 non-null     float64  
dtypes: float64(25), object(1)  
memory usage: 6.6+ KB
```

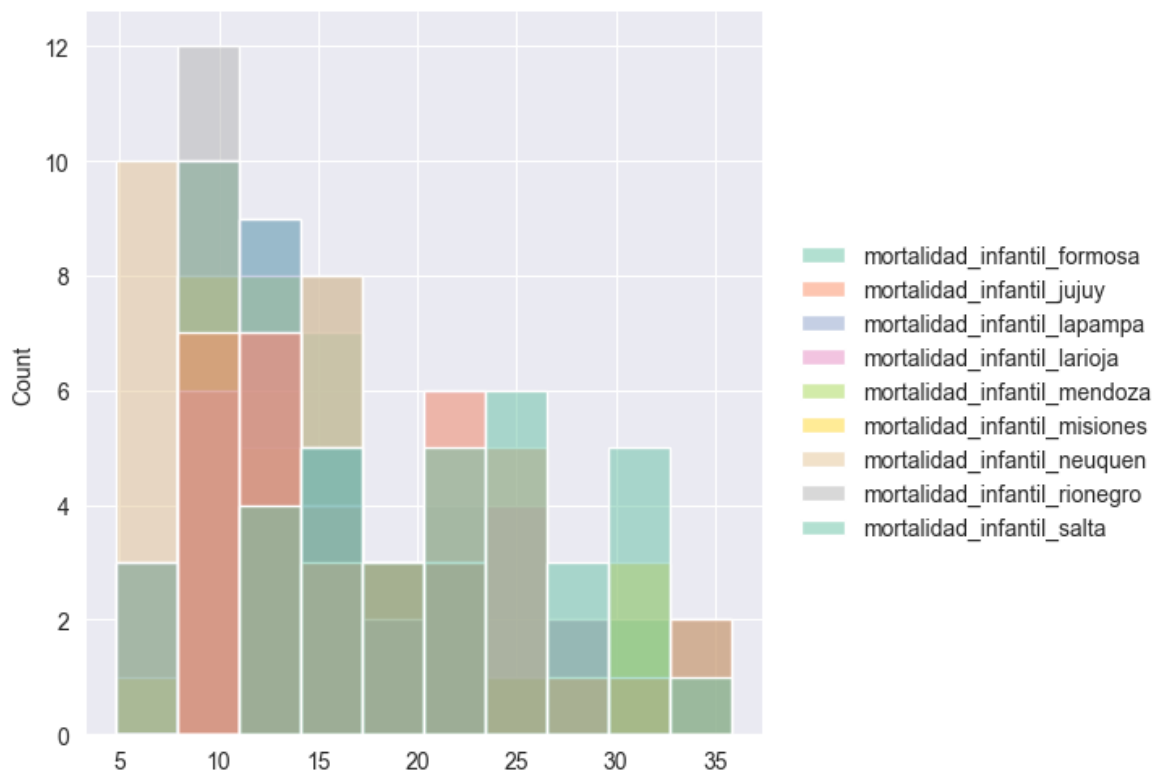
```
In [7]: # al ver que year es tipo objeto ,para clarificar a python lo paso a que e  
#de tiempo  
ds['year'] = pd.to_datetime(ds['year'])
```

```
In [8]: #Para hacer comparaciones al dataset lo fragmento de distinto dataframe  
#asi realizar comparaciones visuales mucho mas comoda ,volviendo a las co  
#dataset original una lista de ellas.  
ds_a_e= ds[list(ds.columns)[:10]]  
ds_d_s= ds[list(ds.columns)[10:19]]  
ds_s_t=ds[list(ds.columns)[19:]]
```


```
In [9]: sns.set_style('darkgrid')  
sns.displot(data=ds_a_e);  
#los graficos a explorar nos dan a entender la cantidad maxima de mortalid  
#por provincia y cuanta veces pasa  
#cada grafico tiene su propio tema de colores
```




```
In [10]: sns.displot(data=ds_d_s ,palette="Set2");
```



```
In [11]: sns.displot(data=ds_s_t, palette="Set3");
```



```
In [12]: sns.displot(data=ds , x = "mortalidad_infantil_argentina");
#para tener una vista de argentina en general nos asegura que normalmente
#mayormente aparecia 7.5 sobre la cantidad de habitantes de mortalidad in
```




```
In [13]: #Aprovechando que tengo una columna de tiempo hare graficos para ver como
#como era la mortalidad_infantil en cada provincia
```

```
# Tramar gráfico de líneas con todas las columnas de valores
fig, ax = plt.subplots(figsize=(12, 8)) # Tamaño de 12x8 pulgadas

# Tramar gráfico de líneas con todas las columnas de valores
ds_a_e.set_index('year', inplace=True)
ds_a_e.plot(kind='line', ax=ax)

plt.show()
```




```
In [14]: # Tramar gráfico de líneas con todas las columnas de valores
fig, ax = plt.subplots(figsize=(12, 8)) # Tamaño de 12x8 pulgadas

# Tramar gráfico de líneas con todas las columnas de valores
ds_d_s = ds_d_s.join(ds["year"])

ds_d_s.set_index("year", inplace=True)
ds_d_s.plot(kind='line', ax=ax)

plt.show()
```




```
In [15]: # Tramar gráfico de líneas con todas las columnas de valores
fig, ax = plt.subplots(figsize=(12, 8)) # Tamaño de 12x8 pulgadas

# Tramar gráfico de líneas con todas las columnas de valores
ds_s_t = ds_s_t.join(ds["year"])

ds_s_t.set_index("year", inplace=True)
ds_s_t.plot(kind='line', ax=ax)

plt.show()
```




```
In [16]: #Este es el grafico donde hago la comparacion general de todas.
```

```
fig, ax = plt.subplots(figsize=(15,15)) # Tamaño de 12x8 pulgadas
```

```
# Tramar gráfico de líneas con todas las columnas de valores  
ds.plot(kind='line', ax=ax , x = "year")
```

```
#Conclusion positiva que puedo alegar a esto es que el pueblo argentino a  
#mejorando aunque sea de poco en el cuidado infantil segun el contexto de  
#igual seria bueno tener informacion sobre como eran esos casos de mortal  
#sin mencionar que hay que revisar que entre 2020 y 2021 se legalizo el a  
#si eso influye en calificacion de mortalidad infantil.
```

```
Out[16]: <Axes: xlabel='year'>
```



```
In [17]: #Para finalizar con este analisis simple quisiera hacer un modelo de regr  
#Donde quiero predecir la mortalidad infantil de caba usando la de buenos  
#siendo tan cercanas debe haber una fuerte relacion supondre.  
regression_model = LinearRegression()
```

```
#x variable predictora  
#y variable a predecir
```

```

X = ds['mortalidad_infantil_buenosaires'].values.reshape(-1, 1) # Asegur
y = ds['mortalidad_infantil_caba'].values
regression_model = LinearRegression()
regression_model.fit(X, y)
coeficiente_angular = regression_model.coef_[0]
intercepto = regression_model.intercept_

print("Coeficiente Angular:", coeficiente_angular)
print("Intercepto:", intercepto)

# Crear una figura y un eje
fig, ax = plt.subplots()

# Graficar los puntos de datos
ax.scatter(X, y, color='blue', label='Datos')

# Calcular los valores predichos utilizando el modelo de regresión lineal
y_pred = regression_model.predict(X)

# Graficar la línea de regresión
ax.plot(X, y_pred, color='red', label='Regresión Lineal')

# Etiquetas de los ejes
ax.set_xlabel('Mortalidad Infantil en Buenos Aires')
ax.set_ylabel('Mortalidad Infantil en CABA')

# Título del gráfico
ax.set_title('Regresión Lineal')

# Leyenda
ax.legend()

# Mostrar el gráfico
plt.show()

#segun el coeficiente angular:
#Esto significa que, en promedio,
#por cada unidad adicional en la variable predictora,
#se espera que la variable objetivo aumente en 0.6187 unidades.
#Indica la pendiente de la línea de regresión.
#Si la variable predictora aumenta en una unidad,
#la variable objetivo aumentará en el coeficiente angular
#osea relacion muy fuerte

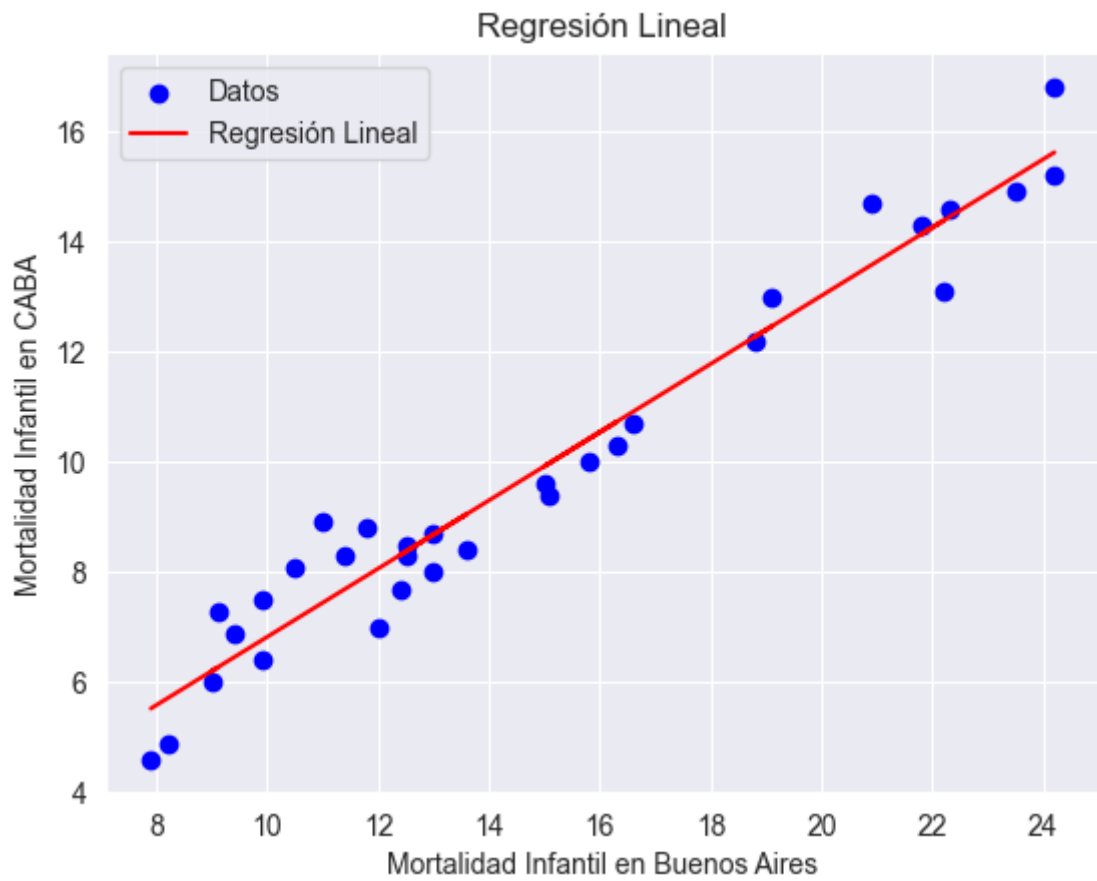
#Intercepto:
#Cuando la variable predictora es cero,
#se espera que la variable objetivo tenga un valor de aproximadamente 0.6
#son muy parecidas demostrando una fuerte relacion.

```

Coeficiente Angular: 0.6187128137787657

Intercepto: 0.6409596988756778





In [ ]: